

0217report

概要

誤分類を含む二値アウトカムに対する、因果効果の推定量に関する手法のシミュレーションを行った結果である。

モデル化の設定

ターゲット分布の潜在結果を以下のように周辺構造モデルを用いて考える。

$E(Y|T, Z)$ を、以下のようにモデル化する

$$E[Y^{(t)} | Z] = E\left[\frac{T}{e^{(t)}}Y | Z\right] = \pi(T, Z; \beta) = \text{expit}\{t\beta_t + z^T\beta_z\} \quad (1)$$

ここで、 $X = (Z, \tilde{Z})$ とし、 Z を共変量全体の中でモデルに必要な共変量とする。

また $e^{(t)}$ は傾向スコア $\Pr(T = t | X)$ である。

データ生成過程

ここでは、共変量 X として考える。 Z に変更した場合の仮定は以前の仮定の整理を確認。

ベルヌーイ分布に従う Y のコンタミのないの分布

$$f(y^{(t)}|x, t; \beta) = \{\pi(t, x)\}^{y^{(t)}} \{1 - \pi(t, x)\}^{1-y^{(t)}} \quad (2)$$

コンタミがある場合の、データ生成過程の設定

$$g(Y = y|X = x, T = t) = c(x)f(y|x, t; \beta) + (1 - c(x))h(y|x, t) \quad (3)$$

$$\eta_0(x) = P(Y = 1|Y_{true} = 0, X = x) \quad (4)$$

$$\eta_1(x) = P(Y = 0|Y_{true} = 1, X = x) \quad (5)$$

- 真の分布 : $f(y|x, t)$
- コンタミの割合 : $1 - c(x) = \eta_0(x) + \eta_1(x)$
- コンタミの分布 : $h(y|x, t)$

シュミレーション設定

共変量

$$XX_i \sim N(0_9, \Sigma) \quad (6)$$

where,

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad (7)$$

処置

$$TT_i \sim \text{Bin}(p) \quad (8)$$

$$\mathbf{lm} = 0.2 + XX_{i1} + XX_{i2} + XX_{i3} + XX_{i4} + XX_{i5} + XX_{i6} + XX_{i7} + XX_{i8} + XX_{i9} \quad (9)$$

$$p = \text{expit}(\mathbf{lm}) \quad (10)$$

潜在アウトカム

$$YY_i^{(1)} \sim \text{Bin}(p1), \quad YY_i^{(0)} \sim \text{Bin}(p0) \quad (11)$$

$$\mathbf{lm1} = 0.2 + 1 + 1 * XX_{i1} - 1 * XX_{i2} + 1 * XX_{i3} \quad (12)$$

$$\mathbf{lm0} = 0.2 + 1 * XX_{i1} - 1 * XX_{i2} + 1 * XX_{i3} \quad (13)$$

$$p1 = \text{expit}(\mathbf{lm1}) \quad (14)$$

$$p0 = \text{expit}(\mathbf{lm0}) \quad (15)$$

つまり、 $Z = (X_1, X_2, X_3)$

観測アウトカム

$$YY_i = TT_i * YY_i^{(1)} + (1 - TT_i) * YY_i^{(0)} \quad (16)$$

誤判別の割合

$$\eta_0 = 0.1, \eta_1 = 0.05 \quad (17)$$

シュミレーション結果

サンプルサイズ、シュミレーション回数はともに 500 である。

表1: 真の値

t	b0	b1	b2	b3
1	0.2	1	-1	1

誤判別がないとき

- $\gamma = 0.00001$ のとき

##	t	b0	b1	b2
##	Min. :0.1460	Min. : -0.29423	Min. :0.5282	Min. : -1.4793
##	1st Qu.:0.7952	1st Qu.: 0.09464	1st Qu.:0.9202	1st Qu.: -1.0999
##	Median :1.0039	Median : 0.20551	Median :1.0130	Median : -0.9970
##	Mean :0.9921	Mean : 0.21005	Mean :1.0175	Mean : -1.0081
##	3rd Qu.:1.1666	3rd Qu.: 0.32282	3rd Qu.:1.1092	3rd Qu.: -0.9197
##	Max. :1.9920	Max. : 0.75937	Max. :1.4117	Max. : -0.6754
##	b3			
##	Min. :0.5848			
##	1st Qu.:0.9198			
##	Median :1.0185			
##	Mean :1.0194			
##	3rd Qu.:1.1059			
##	Max. :1.5137			

- $\gamma = 1$ のとき

##	t	b0	b1	b2
##	Min. :0.1873	Min. : -0.40779	Min. :0.5394	Min. : -1.4899
##	1st Qu.:0.7925	1st Qu.: 0.07247	1st Qu.:0.8857	1st Qu.: -1.0946
##	Median :0.9849	Median : 0.19884	Median :0.9977	Median : -0.9947
##	Mean :0.9790	Mean : 0.21253	Mean :1.0039	Mean : -0.9991
##	3rd Qu.:1.1600	3rd Qu.: 0.33101	3rd Qu.:1.1128	3rd Qu.: -0.8829
##	Max. :1.8881	Max. : 0.84838	Max. :1.6355	Max. : -0.5618
##	b3			
##	Min. :0.4886			
##	1st Qu.:0.8996			
##	Median :1.0038			
##	Mean :1.0097			
##	3rd Qu.:1.1101			
##	Max. :1.7208			

誤判別があるとき

誤判別の設定は、 $\eta_0 = 0.1$, $\eta_1 = 0.05$ である

- $\gamma = 0.00001$ のとき

```
##          t                b0                b1                b2
## Min.    :-0.09453   Min.    :-0.2390   Min.    :0.3618   Min.    :-1.0743
## 1st Qu.: 0.59615   1st Qu.: 0.1699   1st Qu.:0.6569   1st Qu.: -0.8240
## Median : 0.76300   Median : 0.2850   Median :0.7403   Median : -0.7390
## Mean    : 0.75771   Mean    : 0.2756   Mean    :0.7404   Mean    : -0.7447
## 3rd Qu.: 0.90572   3rd Qu.: 0.3812   3rd Qu.:0.8177   3rd Qu.: -0.6564
## Max.    : 1.37592   Max.    : 0.7541   Max.    :1.2435   Max.    : -0.3625
##
##          b3
## Min.    :0.3337
## 1st Qu.:0.6602
## Median :0.7367
## Mean    :0.7451
## 3rd Qu.:0.8283
## Max.    :1.2643
```

- $\gamma = 1$ のとき

```
##          t                b0                b1                b2
## Min.    :0.02884   Min.    :-0.1692   Min.    :0.3246   Min.    :-1.2461
## 1st Qu.:0.63203   1st Qu.: 0.1481   1st Qu.:0.7122   1st Qu.: -0.8820
## Median :0.80964   Median : 0.2854   Median :0.8028   Median : -0.7920
## Mean    :0.81239   Mean    : 0.2742   Mean    :0.8105   Mean    : -0.7967
## 3rd Qu.:0.99609   3rd Qu.: 0.3898   3rd Qu.:0.8977   3rd Qu.: -0.6940
## Max.    :1.74617   Max.    : 0.8643   Max.    :1.2832   Max.    : -0.4523
##
##          b3
## Min.    :0.4801
## 1st Qu.:0.7076
## Median :0.7954
## Mean    :0.8116
## 3rd Qu.:0.9117
## Max.    :1.2935
```

- $\gamma = 2$ のとき

```
##          t                b0                b1                b2
```

##	Min.	:0.04313	Min.	:-0.2801	Min.	:0.4078	Min.	:-1.7998
##	1st Qu.:	0.62166	1st Qu.:	0.1590	1st Qu.:	0.7419	1st Qu.:	-0.9575
##	Median	:0.83875	Median	: 0.2953	Median	:0.8470	Median	:-0.8263
##	Mean	:0.83601	Mean	: 0.3000	Mean	:0.8606	Mean	:-0.8453
##	3rd Qu.:	1.03258	3rd Qu.:	0.4374	3rd Qu.:	0.9770	3rd Qu.:	-0.7151
##	Max.	:1.83847	Max.	: 0.8835	Max.	:1.4504	Max.	:-0.2914
##	b3							
##	Min.	:0.4063						
##	1st Qu.:	0.7196						
##	Median	:0.8357						
##	Mean	:0.8438						
##	3rd Qu.:	0.9446						
##	Max.	:1.5976						

• $\gamma = 3$ のとき

##	t	b0	b1	b2				
##	Min.	:-0.2463	Min.	:-0.4780	Min.	:0.3717	Min.	:-1.5092
##	1st Qu.:	0.6309	1st Qu.:	0.1260	1st Qu.:	0.7364	1st Qu.:	-1.0165
##	Median	: 0.8597	Median	: 0.2888	Median	:0.8733	Median	:-0.8629
##	Mean	: 0.8818	Mean	: 0.2828	Mean	:0.8950	Mean	:-0.8814
##	3rd Qu.:	1.1215	3rd Qu.:	0.4351	3rd Qu.:	1.0149	3rd Qu.:	-0.7416
##	Max.	: 2.2905	Max.	: 1.0109	Max.	:1.5522	Max.	:-0.3581
##	b3							
##	Min.	:0.3616						
##	1st Qu.:	0.7255						
##	Median	:0.8509						
##	Mean	:0.8756						
##	3rd Qu.:	1.0138						
##	Max.	:1.7459						

• $\gamma = 4$ のとき

##	t	b0	b1	b2				
##	Min.	:-0.1147	Min.	:-0.3576	Min.	:0.3728	Min.	:-1.5910
##	1st Qu.:	0.5821	1st Qu.:	0.1619	1st Qu.:	0.7231	1st Qu.:	-1.0469
##	Median	: 0.8419	Median	: 0.3001	Median	:0.8755	Median	:-0.8800
##	Mean	: 0.8440	Mean	: 0.3229	Mean	:0.8856	Mean	:-0.8878
##	3rd Qu.:	1.0622	3rd Qu.:	0.4652	3rd Qu.:	1.0044	3rd Qu.:	-0.7378
##	Max.	: 1.8513	Max.	: 1.3680	Max.	:1.6595	Max.	:-0.3215
##	b3							
##	Min.	:0.3621						

```
## 1st Qu.:0.7337
## Median :0.8696
## Mean   :0.8884
## 3rd Qu.:1.0165
## Max.    :1.7908
```

結果と考察

- 誤判別がないとき、すべてのパラメータで $\gamma \approx 0$ のときに、ほとんどバイアスなく推定できており、求めている挙動通りである
- 誤判別がある時、求めたい対象である治療変数のパラメータ t は $\gamma \approx 0$ のとき、平均 0.75 であるが、 $\gamma = 2$ で平均 0.83、 $\gamma = 3$ で平均 0.88 であり、バイアスの減少は見られるが完全には取り除けていない
- Hung のロバストなロジスティック回帰のシュミレーションを行った際も、論文ではバイアスなく推定できると結果が報告されていたが、自分の再現では 0.1 程度バイアスが残っている
- シュミレーションの実装コードのバグが原因なのではないかと考えているが、原因はわかっていない
- 平均ではなく第三四分位数の値が、真の値に近くなっている結果も、ロバストなロジスティック回帰の再現を行ったときと同じ現象である。